Universidade Federal de Minas Gerais
Escola de Engenharia
ELE077 Otimização Não Linear

Trabalho Computacional I

Luisa Marques Laboissiere Talvani de Souza Barbosa

4 de novembro de 2026

Introdução

Este relatório resolve os quatro problemas de otimização não linear irrestrita do Trabalho Computacional I. Para cada problema, a função-objetivo é analisada quanto a diferenciabilidade, convexidade, modalidade e dimensão; a partir dessa análise escolhe-se o método mais adequado, cujos resultados são apresentados e discutidos.

Todos os métodos foram executados com `scipy.optimize.minimize` (Python 3.12, SciPy 1.18, NumPy 2.5, Matplotlib 3.11). Cada questão corresponde a um script (`questao1.py` a `questao4.py`); os resultados numéricos são gravados em `resultados/questaoN/resultados.json` e as figuras na mesma pasta. A Tabela 1 resume as escolhas.

Tabela 1: Resumo das características de cada problema e do método escolhido.

Problema	Variáveis	Diferenciável	Convexa	Método	Derivadas usadas
1	3	Sim ($x \neq 0$)	Não	BFGS	Gradiente analítico
2	1024	Sim (via ϵ)	Sim	Gradientes Conjugados	Gradiente analítico
3	2	Não	Não (em p)	Nelder–Mead	Nenhuma
4	2	Sim	Estritamente	Newton	Gradiente e Hessiana

1 Problema 1 — Frequência natural fundamental

1.1 Análise da função-objetivo

A função a minimizar é o quociente de Rayleigh

$$R(\mathbf{x}) = \frac{\mathbf{x}^T \mathbf{K} \mathbf{x}}{\mathbf{x}^T \mathbf{M} \mathbf{x}}, \qquad \mathbf{x} \in \mathbb{R}^3 \setminus \{\mathbf{0}\}, \tag{1}$$

com $\mathbf{M} = \mathbf{I}$ e $\mathbf{K}$ dada no enunciado. Suas principais características são:

- **Diferenciabilidade.** R é infinitamente diferenciável em todo ponto com $\mathbf{x} \neq \mathbf{0}$, e o gradiente tem forma fechada simples:

$$\nabla R(\mathbf{x}) = \frac{2\,(\mathbf{K}\mathbf{x} - R(\mathbf{x})\,\mathbf{M}\mathbf{x})}{\mathbf{x}^T \mathbf{M} \mathbf{x}}. \tag{2}$$

- **Invariância de escala.** $R(\alpha \mathbf{x}) = R(\mathbf{x})$ para todo $\alpha \neq 0$. Portanto o minimizador não é um ponto isolado, mas uma reta (sem a origem): só a *direção* de $\mathbf{x}^*$ é determinada, não sua magnitude nem seu sinal.

- **Pontos estacionários.** $\nabla R(\mathbf{x}) = \mathbf{0}$ equivale a $\mathbf{K}\mathbf{x} = R(\mathbf{x})\mathbf{M}\mathbf{x}$, isto é, os pontos estacionários são exatamente os autovetores do problema generalizado $(\mathbf{K}, \mathbf{M})$, e o valor de R em cada um é o autovalor correspondente. Com $\lambda_1 < \lambda_2 < \lambda_3$, o primeiro autovetor é mínimo global, o segundo é ponto de sela e o terceiro é máximo global.

- **Convexidade e modalidade.** R não é convexa (possui ponto de sela e máximo), mas todo mínimo local é global: não existem mínimos locais espúrios.

- **Hessiana.** No ótimo, $\nabla^2 R(\mathbf{x}^*) = 2(\mathbf{K} - \lambda_1 \mathbf{M})/(\mathbf{x}^{*T}\mathbf{M}\mathbf{x}^*)$, que é semidefinida positiva e *singular* (anula-se na direção do próprio $\mathbf{x}^*$, consequência da invariância de escala). Fora do ótimo, a Hessiana pode ser indefinida.

Como R só depende da direção de $\mathbf{x}$, é possível visualizar a função fixando $x_3 = 1$: qualquer vetor com $x_3 \neq 0$ pode ser reescalado para esse plano sem alterar R. A Figura 1 (esquerda) mostra as curvas de nível de $R(x_1, x_2, 1)$ com os três autovetores marcados, evidenciando o vale do mínimo, o ponto de sela e o máximo.

1.2 Escolha do método: BFGS

- A função é suave e o gradiente analítico é barato, logo um método baseado em gradiente é natural; métodos de ordem zero (como Nelder–Mead) desperdiçariam essa informação.

- O **método de Newton** não é adequado: a Hessiana é singular no ótimo e pode ser indefinida em outros pontos, de modo que o passo de Newton pode não estar definido ou não ser direção de descida.

- O **BFGS** constrói uma aproximação da Hessiana que se mantém definida positiva, garantindo direções de descida, e converge de forma superlinear, muito mais rápido que o gradiente descendente.

- A dimensão é pequena ($n = 3$), de modo que o custo de armazenar e atualizar a matriz 3×3 do BFGS é desprezível.

1.3 Resultados

Utilizou-se `method='BFGS'` com o gradiente analítico, ponto inicial $\mathbf{x}_0 = (1, 1, 1)$ e tolerância `gtol`$= 10^{-10}$. A Tabela 2 resume os resultados.

Tabela 2: Resultados do Problema 1 (BFGS).

Grandeza	Valor
$\mathbf{x}^*$	(0,6084; 1,0962; 1,3670)
$\mathbf{x}^*/x_3^*$	(0,4450; 0,8019; 1)
$R(\mathbf{x}^*) = \omega_1^2$	0,198062264195
ω_1	0,44504 rad/s
Iterações	7
Avaliações de f / de ∇f	8 / 8
$\lvert R(\mathbf{x}^*) - \lambda_{\min}(\mathbf{K})\rvert$	$1{,}9 \times 10^{-16}$
Erro de direção em relação ao autovetor	$2{,}2 \times 10^{-12}$
$\lVert\nabla R(\mathbf{x}^*)\rVert$	$4{,}3 \times 10^{-12}$

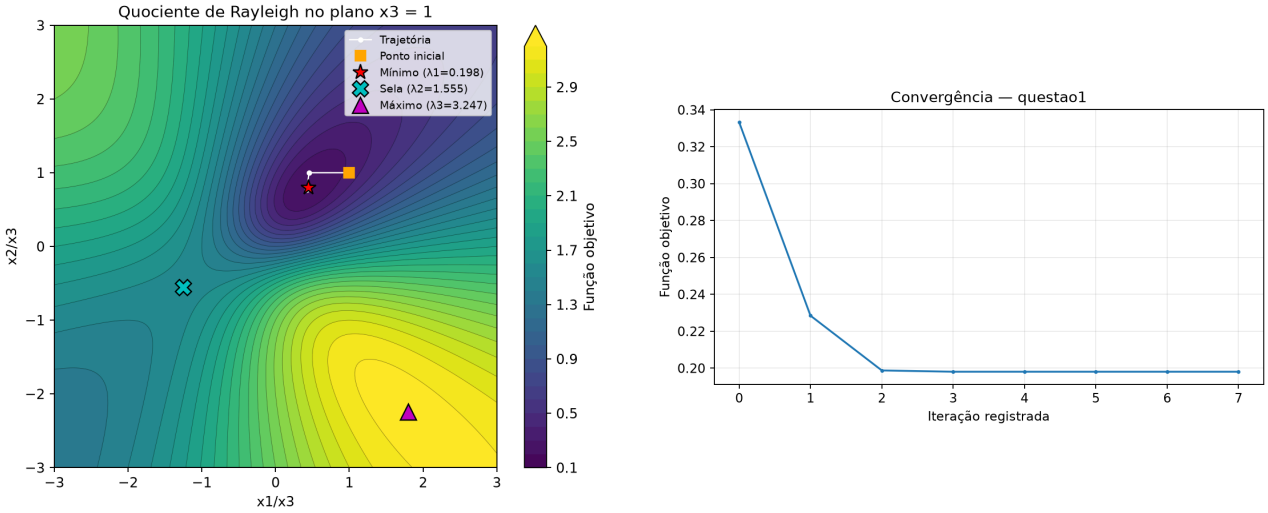


Figura 1: Problema 1. Esquerda: curvas de nível de R no plano $x_3 = 1$, com a trajetória do BFGS projetada e os três autovetores de $\mathbf{K}$. Direita: valor de R por iteração.

1.4 Discussão

O BFGS encontrou $\omega_1^2 = 0{,}198062$, que coincide com o menor autovalor de $\mathbf{K}$ calculado por `numpy.linalg.eigh` até a precisão de máquina, resultando em uma frequência natural fundamental $\omega_1 \approx 0{,}445$ rad/s. O valor também concorda com a expressão fechada $\lambda_1 = 2 - 2\cos(\pi/7) \approx 0{,}198062$ para esta matriz tridiagonal. A direção encontrada coincide com o primeiro autovetor (erro de 2×10^{-12}), e o resíduo $\lVert\mathbf{K}\mathbf{v} - R\,\mathbf{M}\mathbf{v}\rVert$ é da ordem de 4×10^{-12}.

A convergência foi superlinear: o erro $R(\mathbf{x}_k) - \lambda_1$ passou de $1{,}4 \times 10^{-1}$ para 3×10^{-2}, 7×10^{-4}, 10^{-6} e 6×10^{-11} em iterações sucessivas, totalizando 7 iterações e 8 avaliações de função e gradiente. Na Figura 1 vê-se que a trajetória vai diretamente para o vale do mínimo, sem passar perto do ponto de sela.

A magnitude de $\mathbf{x}^*$ obtida ($\lVert\mathbf{x}^*\rVert \approx 1{,}85$) é arbitrária: ela depende apenas do ponto inicial, pois o otimizador para em algum ponto da reta de minimizadores. Fisicamente, $\mathbf{x}^*$ é o *modo de*

vibração fundamental: as três massas se deslocam no mesmo sentido, com amplitudes crescentes da massa 1 para a massa 3 (razão 0,445 : 0,802 : 1).

2 Problema 2 — Restauração de imagem por variação total

2.1 Análise da função-objetivo

A função a minimizar é

$$f(x) = \|Ax - b\|_2^2 + \lambda \sum_{i,j} \sqrt{(X_{i+1,j} - X_{i,j})^2 + (X_{i,j+1} - X_{i,j})^2 + \epsilon}, \tag{3}$$

com $x \in \mathbb{R}^n$ a imagem 32×32 achatada, ou seja, $n = 1024$ variáveis. Na implementação, $\lambda = 0{,}02$, $\epsilon = 10^{-8}$, A é a convolução com um núcleo gaussiano 9×9 com contorno periódico, e b é a imagem borrada com ruído gaussiano de desvio 0,05 (semente fixa).

- **Dimensão.** Com 1024 variáveis, esta é de longe a maior dimensão do trabalho, e é o fator que mais pesa na escolha do método.
- **Diferenciabilidade.** Sem ϵ, o termo $\sqrt{u^2 + v^2}$ não é diferenciável onde $u = v = 0$, isto é, em regiões planas da imagem. Com $\epsilon > 0$ a função é suave em todo $\mathbb{R}^n$. O gradiente foi implementado analiticamente:

  $$\nabla f(x) = 2A^T(Ax - b) + \lambda \nabla \mathrm{TV}(x), \tag{4}$$

  com A^T aplicado como convolução com o núcleo rotacionado e ∇TV calculado pelo adjunto das diferenças periódicas. O gradiente foi validado por diferenças finitas centrais em 10 componentes sorteadas, com erro máximo de $1{,}1 \times 10^{-9}$.
- **Convexidade.** O termo de fidelidade é uma quadrática convexa (A é linear). Cada parcela $\sqrt{u^2 + v^2 + \epsilon}$ é a norma euclidiana do vetor $(u, v, \sqrt{\epsilon})$, portanto convexa em (u, v), e (u, v) dependem linearmente de x. Logo f é convexa e todo mínimo local é global (função unimodal).
- **Condicionamento.** A curvatura de $\sqrt{s^2 + \epsilon}$ em $s = 0$ é $1/\sqrt{\epsilon} = 10^4$; multiplicada por λ, chega a ~ 200 em regiões planas, enquanto o termo de fidelidade tem curvatura no máximo 2 (o núcleo é normalizado). O problema é, portanto, mal condicionado, o que torna a convergência lenta para métodos de primeira ordem.

2.2 Escolha do método: Gradientes Conjugados não lineares

- Os **Gradientes Conjugados** usam apenas o gradiente e memória $O(n)$, e, ao construir direções conjugadas, evitam o ziguezague do gradiente descendente em problemas mal condicionados. Como a função é convexa e o gradiente analítico é barato (duas convoluções e operações elemento a elemento), o CG é a escolha mais adequada entre os métodos estudados.
- O **método de Newton** exigiria formar e fatorar a Hessiana 1024×1024 a cada iteração, o que é caro e desnecessário.

- O **BFGS** armazena uma matriz densa $n \times n$ (cerca de 10^6 entradas) com custo $O(n^2)$ por iteração. É viável, mas pesado, e a dica do enunciado (começar com poucas iterações) indica que o custo computacional é relevante.
- O **Nelder–Mead** é inviável porque o simplex teria 1025 vértices e o número de avaliações seria proibitivo.

2.3 Resultados

Utilizou-se `method='CG'` com o gradiente analítico, ponto inicial $x_0 = b$ (a própria imagem degradada), `gtol`$= 10^{-5}$ e no máximo 1000 iterações. A Tabela 3 resume os resultados.

Tabela 3: Resultados do Problema 2 (Gradientes Conjugados).

Grandeza	Inicial ($x_0 = b$)	Final
$f(x)$	8,652	3,861
Fidelidade $\|Ax - b\|_2^2$	6,451	1,742
TV(x)	110,04	105,94
Iterações	1000 (limite atingido)	
Avaliações de f / de ∇f	1414 / 1414	
$\|\nabla f(x_{\text{final}})\|$	$4{,}9 \times 10^{-2}$	

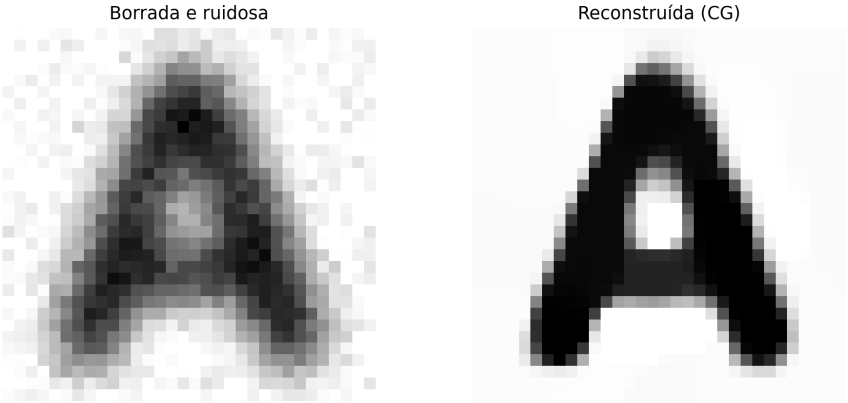


Figura 2: Problema 2. Imagem borrada e ruidosa b (esquerda) e imagem reconstruída pelo CG após 1000 iterações (direita).

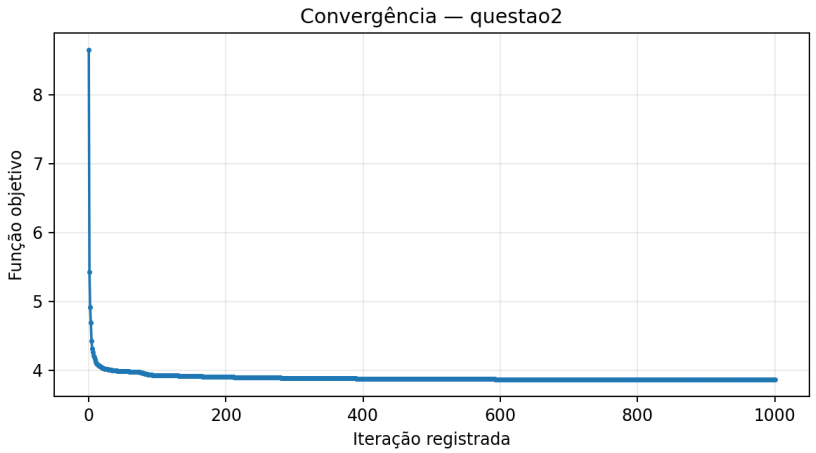


Figura 3: Problema 2. Valor de f por iteração do CG.

2.4 Discussão

O CG reduziu a função-objetivo em cerca de 55% (8,65 → 3,86). A maior parte da redução veio do termo de fidelidade (6,45 → 1,74): ao contrário de b, que é a imagem borrada, a reconstrução x é tal que Ax (a reconstrução borrada) se aproxima de b. O termo TV também diminuiu levemente (110,0 → 105,9), refletindo a remoção do ruído nas regiões de fundo.

Visualmente (Figura 2), a reconstrução é muito mais nítida que a imagem degradada: a letra "A" tem bordas bem definidas, o fundo ficou praticamente uniforme e a abertura interna da letra é claramente visível. Esse é o comportamento esperado da regularização por variação total, que favorece imagens constantes por partes e preserva bordas.

Quanto à convergência (Figura 3), a função cai rapidamente nas primeiras iterações ($f =$ 4,12 após 10 iterações e 3,93 após 100) e depois decresce muito lentamente: entre as iterações 100 e 1000 a redução é de menos de 2%. O algoritmo parou pelo limite de 1000 iterações, sem atingir a tolerância de gradiente ($\|\nabla f\| \approx 0{,}049 > 10^{-5}$); ou seja, o ótimo não foi atingido com alta precisão. Esse comportamento é coerente com o mau condicionamento causado pelo ϵ pequeno na TV: o CG avança rapidamente nas direções bem condicionadas e lentamente nas demais.

Por fim, como o problema é irrestrito, não se impôs que os pixels ficassem em $[0, 1]$: a reconstrução tem valores entre $-0{,}031$ e 1,028 (36 pixels abaixo de 0 e 68 acima de 1). As violações são pequenas e a figura usa a escala visual $[0, 1]$.

3 Problema 3 — Precificação minimax

3.1 Análise da função-objetivo

A função a minimizar é

$$F(p_1, p_2) = \max_{i=1,\ldots,4} \left| \frac{a_{1,i}}{p_1} + \frac{a_{2,i}}{p_2} - R_{\text{alvo}} \right|, \qquad p_1, p_2 > 0, \tag{5}$$

com $R_{\text{alvo}} = 10000$ e os parâmetros da Tabela 1 do enunciado. Suas características são:

- **Dimensão.** Apenas 2 variáveis, restritas a valores positivos.
- **Não diferenciabilidade.** O valor absoluto não é diferenciável onde o desvio de um cenário se anula, e o máximo não é diferenciável onde dois cenários empatam como pior

caso. A função é contínua mas apresenta "quinas". Em problemas minimax, o ótimo tipicamente fica *exatamente* em uma dessas quinas, pois a solução equilibra os piores desvios.

- **Convexidade.** Com a troca $u = 1/p_1$, $v = 1/p_2$, cada receita é linear em (u, v) e F torna-se o máximo de valores absolutos de funções afins, ou seja, uma função convexa e linear por partes em (u, v). Como cada preço corresponde a um único par (u, v) e vice-versa, um mínimo local nos preços também é mínimo local em (u, v) e, pela convexidade, é global. Assim, F não tem mínimos locais "falsos", mesmo não sendo convexa nos preços.

- **Estrutura dos cenários.** Os cenários 1, 2 e 3 são proporcionais: os cenários 2 e 3 valem 0,7 e 1,3 vezes o cenário 1. Definindo $s = 100000/p_1 + 80000/p_2$, tem-se $R_1 = s$, $R_2 = 0{,}7s$ e $R_3 = 1{,}3s$. Se $s \geq R_{\text{alvo}}$, então $|R_3 - R_{\text{alvo}}| \geq 0{,}3R_{\text{alvo}}$; se $s \leq R_{\text{alvo}}$, então $|R_2 - R_{\text{alvo}}| \geq 0{,}3R_{\text{alvo}}$. Logo $F \geq 3000$ em todo o domínio, com igualdade quando $s = R_{\text{alvo}}$ e o cenário 4 não excede esse desvio. Sobre a curva $s = R_{\text{alvo}}$ verifica-se que $R_4 \in (9000, 11250)$, de modo que o cenário 4 nunca é o pior. Assim, **o valor ótimo é 3000 e o conjunto de ótimos é a curva**

$$\frac{100000}{p_1} + \frac{80000}{p_2} = 10000, \qquad p_1 > 10,\ p_2 > 8, \tag{6}$$

  e não um ponto isolado.

3.2 Escolha do método: Nelder–Mead Simplex

- Métodos baseados em gradiente (gradiente descendente, BFGS, CG, Newton) pressupõem uma função diferenciável. Aqui o gradiente não existe justamente no ótimo, a busca linear tende a falhar nas quinas e as aproximações de Hessiana do BFGS perdem o sentido.

- O **Nelder–Mead** usa apenas valores da função, sem derivadas, e por isso não é afetado pelas quinas.

- Com apenas 2 variáveis, o simplex tem 3 vértices e o custo por iteração é desprezível. A ausência de garantias gerais de convergência do Nelder–Mead não é preocupante aqui, pois o resultado pode ser verificado pelo limitante inferior $F \geq 3000$ deduzido acima.

Para manter os preços estritamente positivos sem impor restrições, otimizou-se nas variáveis $z_j = \ln p_j$, isto é, $p_j = e^{z_j}$. Trata-se apenas de uma mudança de variáveis; o algoritmo de otimização continua sendo o Nelder–Mead irrestrito.

3.3 Resultados

Utilizou-se `method='Nelder-Mead'` com ponto inicial $p_0 = (12, 25)$, `xatol`$= 10^{-12}$ e `fatol`$= 10^{-9}$. Os resultados estão na Tabela 4.

Tabela 4: Resultados do Problema 3 (Nelder–Mead).

Cenário	Receita R_i	Desvio $\lvert R_i - R_{\text{alvo}}\rvert$
1 — Mercado Normal	10000,0	0,0
2 — Recessão Econômica	7000,0	3000,0
3 — Alta Demanda	13000,0	3000,0
4 — Pressão Competitiva	9770,2	229,8
Preços ótimos (p_1, p_2)	(15,204; 23,372)	
Pior desvio $F(p^*)$	3000,0	
Iterações / avaliações de F	116 / 250	

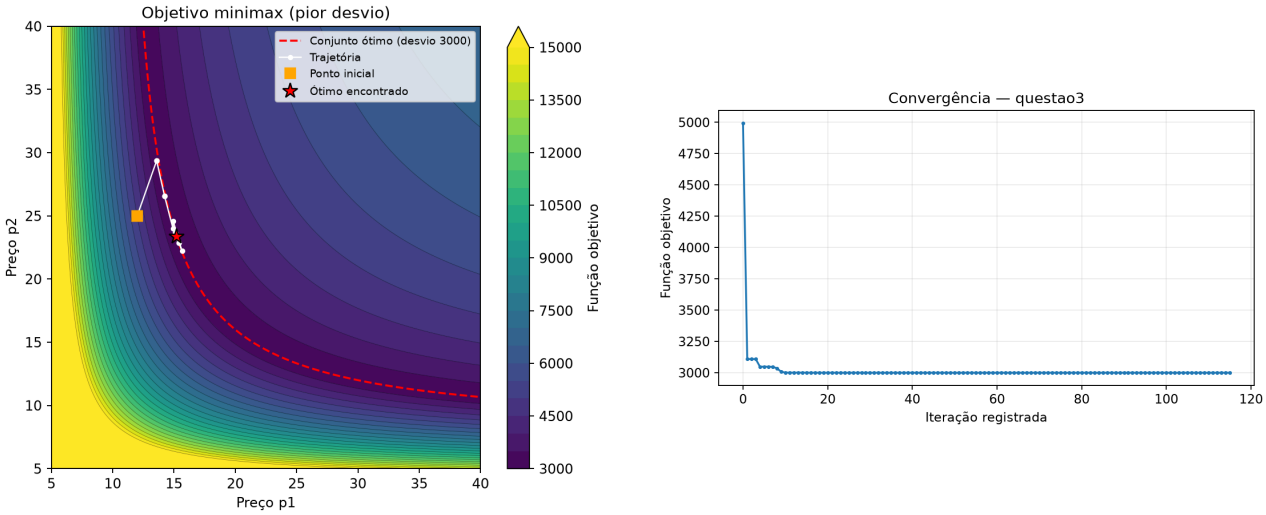


Figura 4: Problema 3. Esquerda: curvas de nível do pior desvio, com a trajetória do Nelder–Mead e a curva de ótimos (tracejada). Direita: pior desvio por iteração.

3.4 Discussão

O Nelder–Mead atingiu o valor ótimo $F = 3000$, que coincide com o limitante inferior obtido analiticamente. A solução encontrada satisfaz $R_1 = 10000$, ou seja, está exatamente sobre a curva de ótimos, e nela os cenários 2 (Recessão) e 3 (Alta Demanda) empatam como pior caso, com desvios de 3000 para baixo e para cima, respectivamente. Esse empate é a "quina" em que se encontra o ótimo, confirmando que a função não é diferenciável na solução. O cenário 4 fica bem abaixo do pior caso (desvio de 230).

A Figura 4 mostra que o pior desvio cai de 4993 para cerca de 3001 em aproximadamente 10 iterações; as iterações restantes apenas contraem o simplex até as tolerâncias muito pequenas adotadas. No gráfico de curvas de nível, a região de valor mínimo forma um vale estreito ao longo da curva tracejada, e a trajetória termina sobre ela.

Uma consequência importante da análise é que **os preços ótimos não são únicos**: qualquer par (p_1, p_2) sobre a curva $100000/p_1 + 80000/p_2 = 10000$ garante o mesmo pior desvio de 3000. Os preços (15,20; 23,37) reportados são apenas o ponto da curva ao qual o Nelder–Mead chegou a partir de $p_0 = (12, 25)$; outro ponto inicial levaria, em geral, a outro par de preços com o mesmo valor ótimo. Na prática, a empresa pode escolher qualquer ponto dessa curva usando um critério adicional (por exemplo, a receita no cenário 4 ou restrições comerciais sobre os preços).

4 Problema 4 — Equilíbrio do sistema de carrinhos

4.1 Análise da função-objetivo

A energia potencial é

$$U(x_1, x_2) = \tfrac{1}{2}k_2 x_1^2 + \tfrac{1}{2}k_3(x_2 - x_1)^2 + \tfrac{1}{2}k_1 x_2^2 - P x_2, \tag{7}$$

que pode ser escrita como uma forma quadrática

$$U(\mathbf{x}) = \tfrac{1}{2}\mathbf{x}^T\mathbf{H}\mathbf{x} - \mathbf{c}^T\mathbf{x}, \qquad \mathbf{H} = \begin{bmatrix} k_2 + k_3 & -k_3 \\ -k_3 & k_1 + k_3 \end{bmatrix} = \begin{bmatrix} 3500 & -2000 \\ -2000 & 3000 \end{bmatrix}, \qquad \mathbf{c} = \begin{bmatrix} 0 \\ P \end{bmatrix}. \tag{8}$$

- **Diferenciabilidade.** U é um polinômio de grau 2, portanto infinitamente diferenciável, com gradiente $\nabla U = \mathbf{H}\mathbf{x} - \mathbf{c}$ e Hessiana constante $\mathbf{H}$.
- **Convexidade.** $\det \mathbf{H} = 6{,}5 \times 10^6 > 0$ e $\operatorname{tr}\mathbf{H} > 0$, logo $\mathbf{H}$ é definida positiva (autovalores 1234,4 e 5265,6). A função é *estritamente convexa* e possui um único mínimo global.
- **Condicionamento.** O número de condição de $\mathbf{H}$ é 5265,6/1234,4 $\approx$ 4,3, moderado. As curvas de nível são elipses inclinadas, pois $\mathbf{H}$ acopla x_1 e x_2.

4.2 Escolha do método: Newton

O método de Newton aproxima a função, a cada iteração, por seu modelo quadrático de segunda ordem e salta para o mínimo desse modelo. Como U *já é* quadrática, o modelo é exato e o primeiro passo

$$\mathbf{x}_1 = \mathbf{x}_0 - \mathbf{H}^{-1}\nabla U(\mathbf{x}_0) = \mathbf{H}^{-1}\mathbf{c} \tag{9}$$

leva ao ótimo a partir de qualquer ponto inicial. Além disso, a Hessiana é constante, conhecida analiticamente e definida positiva, de modo que usá-la não tem custo extra nem risco de direção de subida. Nenhum outro método estudado converge em menos iterações para este problema.

Como a SciPy não oferece o método de Newton puro, usou-se `method='Newton-CG'` com gradiente e Hessiana analíticos. Esse método resolve o sistema de Newton $\mathbf{H}\mathbf{d} = -\nabla U$ por gradientes conjugados internos, o que, para um sistema 2×2 definido positivo, é exato em no máximo 2 passos internos; na prática, equivale ao Newton.

4.3 Resultados

Com ponto inicial $\mathbf{x}_0 = (0, 0)$ e `xtol`$= 10^{-12}$, obtiveram-se os resultados da Tabela 5.

Tabela 5: Resultados do Problema 4 (Newton).

Grandeza	Valor
x_1^*	0,030769 m (= 2/65)
x_2^*	0,053846 m (= 3,5/65)
$U(\mathbf{x}^*)$	−2,6923 J
Iterações	2
Avaliações de f / de ∇f	2 / 2
Erro em relação à solução analítica $\mathbf{H}^{-1}\mathbf{c}$	$6{,}9 \times 10^{-18}$
$\lVert\nabla U(\mathbf{x}^*)\rVert$	$1{,}7 \times 10^{-14}$

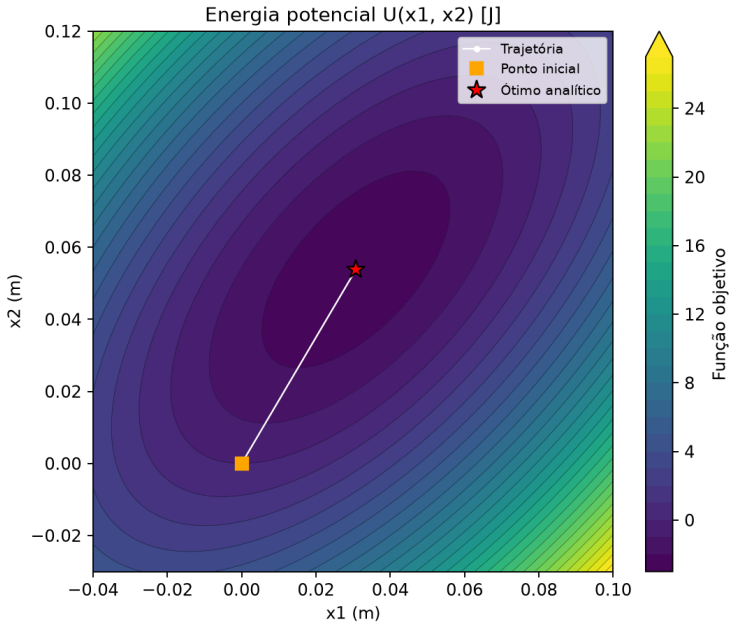


Figura 5: Problema 4. Curvas de nível da energia potencial U, com a trajetória do método de Newton a partir de $\mathbf{x}_0 = (0, 0)$.

4.4 Discussão

A posição de equilíbrio é $x_1^* \approx 30{,}8$ mm e $x_2^* \approx 53{,}8$ mm, idêntica à solução analítica de $\mathbf{Hx} = \mathbf{c}$ até a precisão de máquina. A energia potencial mínima é $U^* = -2{,}692$ J, que satisfaz a relação $U^* = -\frac{1}{2} P x_2^*$ válida no equilíbrio de sistemas lineares. Fisicamente, ambos os carrinhos se deslocam no sentido da força P, com $x_2^* > x_1^*$: o carrinho B, onde a força é aplicada, desloca-se mais, e a mola k_3 fica esticada, transmitindo parte da força ao carrinho A.

A Figura 5 ilustra a análise: as curvas de nível são elipses concêntricas em torno de um único ponto (convexidade estrita), e o Newton vai de $(0, 0)$ ao ótimo em um único passo retilíneo. A SciPy reporta 2 iterações porque, após o primeiro passo já atingir o ótimo (U passa de 0 para $-2{,}6923$), uma segunda iteração com passo desprezível é executada antes de o critério de parada `xtol` ser satisfeito; o valor de U não se altera nessa segunda iteração. O resultado confirma que, para funções quadráticas estritamente convexas, o método de Newton converge em uma iteração.

Conclusões

A escolha do método em cada problema seguiu o mesmo critério: usar a maior quantidade de informação de derivadas que a função permite, desde que o custo computacional seja viável.

- No **Problema 4**, a função é quadrática com Hessiana constante e definida positiva, e o **método de Newton** converge em uma única iteração.
- No **Problema 1**, a função é suave mas tem Hessiana singular no ótimo e indefinida fora dele; o **BFGS**, com aproximação definida positiva da Hessiana, convergiu superlinearmente em 7 iterações para o menor autovalor de $\mathbf{K}$, com $\omega_1 \approx 0{,}445$ rad/s.
- No **Problema 2**, a dimensão elevada ($n = 1024$) torna inviável o uso de Hessianas; os **Gradientes Conjugados**, com memória $O(n)$, recuperaram uma imagem nítida,

embora o mau condicionamento introduzido pelo ϵ da variação total tenha impedido a convergência com alta precisão dentro de 1000 iterações.

- No **Problema 3**, a função minimax não é diferenciável no ótimo, e o **Nelder–Mead**, que não usa derivadas, atingiu o pior desvio mínimo de 3000. A análise mostrou ainda que existe uma curva inteira de preços ótimos.

Em todos os casos os resultados numéricos foram validados de forma independente: por autovalores (Problema 1), por diferenças finitas do gradiente (Problema 2), por um limitante inferior analítico (Problema 3) e pela solução de um sistema linear (Problema 4).

Códigos-fonte

Os códigos acompanham este relatório: `questao1.py` a `questao4.py` (um por problema), `comum.py` (exportação dos resultados e geração de gráficos) e `utils.py` (leitura da imagem e operador de borrão, fornecidos com o enunciado). Para reproduzir os resultados, basta instalar as dependências com `pip install -r requirements.txt` e executar cada script a partir da pasta do projeto.